Formális nyelvek és a fordítóprogramok alapjai

Előadók: Nagy Sára, mesteroktató
Algoritmusok és Alkalmazásaik Tanszék
Dr. Horpácsi Dániel, adjunktus
Programozási Nyelvek és Fordítóprogramok Tanszék

Elérhetőség:

Nagy Sára

Fogadóóra: csütörtök 15-16 óráig,

2.608-as szoba vagy Teams-ben

(2022/23. 2. félévben)

E-mail: saci@inf.elte.hu

A formális nyelvek rész tartalma:

- A formális nyelvek és automaták alapvető fogalmainak megismertetése, a közöttük fennálló összefüggések bemutatása.

- A formális nyelvek elmélete szimbólumsorozatok halmazainak véges, tömör leírásának különféle módszereit adja. Módszereket ad annak eldöntésére, hogy egy szimbólumsorozat hozzátartozik-e egy adott formális nyelvhez vagy sem.

Kapcsolódó tudományágak

- Fordítóprogramok
- Természetes nyelvek gépi feldolgozása
- Képfeldolgozás
- Molekuláris számítás (DNS számítás)
- stb.

Irodalom:

- A. Salomaa, Formal Languages, Academic Press, 1973.
- Révész György, Bevezetés a formális nyelvek elméletébe, Tankönyvkiadó, 1977.
- Bach Iván: Formális nyelvek, Typotex, 2001.
- Fülöp Zoltán, Formális nyelvek és szintaktikus elemzésük, Polygon, Szeged, 2004.
- Hunyadvári László, Manhertz Tamás, Automaták és formális nyelvek, Elektronikus előadásjegyzet, 2006.
- Csima Judit, Friedl Katalin: Nyelvek és automaták, BMGE jegyzet, 2013.

Alapfogalmak és jelölések

Ábécé: Ábécének nevezzük a jelek egy nem üres véges halmazát. Jele: V

Betű: Az ábécé elemeit betűknek hívjuk. ($a \in V$)

Szó: A V ábécé elemeinek egy tetszőleges véges sorozatát a V ábécé feletti szónak nevezzük. (Ha V nem lényeges vagy egyértelmű, akkor szóról beszélünk.)

Ha u egy tetszőleges szó, akkor $\ell(u)$ jelöli a szó hosszát.

$0 \leq \ell(u) < \infty$; $\ell(\varepsilon) = 0$, ahol ε az üres szó.

Alapfogalmak és jelölések

A V ábécé feletti szavak halmazát V*-gal jelöljük. A nem üres szavakét V^+-szal.

Nyelv: V* valamely részhalmazát a V ábécé feletti nyelvnek nevezzük. Jele: L

$$L \subseteq V^*$$

Nyelvosztály (nyelvcsalád): Nyelvek valamely összességét nyelvosztálynak hívjuk.

Példák nyelvekre

V_1 ={a,b,c}

L_1 = { aab, b, acc, bab, a, bb }

L_2 = { u $\in V_1^*$ | u-ban pontosan egy darab ‚a' betű van. }

Lexikografikusan felsorolva:

L_2 = { a, ab, ac, ba, ca, abb, abc, acb, acc, bab, bac, bba, bca, cab, cac, cba, cca, … }

V_2 = {!,#,@}

L_3 = { u $\in V_2^*$ | u-ban nincs @ betű. }

Lexikografikusan felsorolva:

L_3 = {ε, !, #, !!, !#, #!, ##, !!!, !!#, … }

L_4 = {ε} az üres szót tartalmazó nyelv.

L_5 = Ø az üres nyelv, ami egy üres halmaz.

Műveletek szavakon

Két szó konkatenációja:

Legyenek $u = t_1 \dots t_k$ és $v = q_1 \dots q_m$ szavak egy V^* felett értelmezve.
Ekkor a két szó konkatenáltja az

$uv := t_1 \dots t_k q_1 \dots q_m$

(A két szó egymás utáni leírásával kapott szó.)

Műveletek szavakon

V^* zárt a konkatenáció műveletére.

V^* a konkatenációra nézve egységelemes félcsoportot alkot.

Asszociatív: $u,v,w \in V^*$

$$(uv)w = u(vw)$$

Egységelem: ε (üres szó) és $v \in V^*$

$$\varepsilon v = v = v\varepsilon$$

Műveletek szavakon

Szó hatványa:

Legyen u egy tetszőleges szó.

Nemnegatív egész hatványai:

$u^0 := \varepsilon$

$u^1 := u$

$u^n := u^{n-1}u$, ahol $n \geq 1$.

Műveletek szavakon

Szó megfordítása:

Ha u egy tetszőleges szó és $u = t_1 \dots t_k$

és $v = t_k \dots t_1$,akkor v az u fordítottja, másképpen mondva a tükörképe.

Jelölése: $u^{-1} = v$

További alapfogalmak

- **Részszó:** A *v* *u*-nak részszava, ha léteznek olyan $w_1;w_2$ szavak, hogy $u = w_1vw_2$.

- **Szó prefixe:** A *v* az *u* szó prefixe, ha van olyan *w* szó, hogy $u = vw$.
  Valódi prefix, ha $v \neq \varepsilon$ és $v \neq u$.

- **Szó suffixe:** A *v* az *u* szó suffixe, ha van olyan *w* szó, hogy $u = wv$.
  Valódi suffix, ha $v \neq \varepsilon$ és $v \neq u$.

Példák

Legyen V={a,b,c}.

u=aabbabbc

v=aab //v prefixsze az u-nak

u=aabbabbc

w=abbc // w suffixe u-nak

u=aabbabbc

z=bb // z részszava u-nak, két helyen is

Műveletek nyelveken

Két nyelv uniója:

Legyenek L_1 és L_2 nyelvek V^* felettiek.

Ekkor az L_1 és L_2 nyelvek unióján az

$L_1 \cup L_2 := \{u \in V^* \mid u \in L_1 \text{ vagy } u \in L_2\}$ nyelvet értjük.

Műveletek nyelveken

Az unió kommutatív, asszociatív és egység-elemes művelet.

Az egységelem az üres nyelv (üres halmaz).

Jele: Ø

Ø ∪ L = L = L ∪ Ø

Műveletek nyelveken

Két nyelv metszete:

Legyenek L_1 és L_2 nyelvek V^* felettiek.

Ekkor az L_1 és L_2 nyelvek metszetén az

$L_1 \cap L_2 := \{u \in V^* \mid u \in L_1 \text{ és } u \in L_2\}$ nyelvet értjük.

Műveletek nyelveken

Az $L \subseteq V^*$ nyelv **komplementere** a

V ábécére vonatkozóan:

$$\overline{L} := V^* \setminus L$$

,azaz minden olyan szó, ami nem tartozik az L nyelvbe.

$\overline{L} \cap L = \emptyset$ és $\overline{L} \cup L = V^*$

Műveletek nyelveken

Az $L \subseteq V^*$ nyelv **tükörképe** az a nyelv, amely a szavainak megfordítottját tartalmazza.
Jele: L^{-1}

$L^{-1} := \{u \in V^* \mid u^{-1} \in L\}$

Példa:

$L = \{abc, aabb, acaa, baab\}$

$L^{-1} = \{cba, aaca, baab, bbaa\}$

Műveletek nyelveken

Két nyelv konkatenációja:

Legyenek L_1 és L_2 nyelvek. Ekkor az L_1 és L_2 nyelvek konkatenációján az

$L_1L_2 := \{uv \mid u \in L_1$ és $v \in L_2\}$ nyelvet értjük.

A nyelvek halmaza a konkatenációra nézve egység elemes félcsoport alkot.

Egység elem: $\{\varepsilon\}$
(az üres szót tartalmazó nyelv)

$\{\varepsilon\}L = L = L\{\varepsilon\}$

$\emptyset L = \emptyset = L\emptyset$

Pédák

Legyen $L_1 = \{a, ab, bb\}$ és $L_2 = \{b, ba\}$.

$L_1L_2 = \{ ab, abb, bbb\} \cup \{aba, abba, bbba \}$
$= \{ ab, aba, abb, bbb, abba, bbba\}$

Legyen $L_1 = \{a, ab\}$ és $L_2 = \{\varepsilon, b\}$.

$L_1L_2 = \{ a\varepsilon, ab\varepsilon\} \cup \{ab, abb\} = \{ a, ab, abb\}$

Legyen $L = \{a, ab, b\}$.

$LL = \{ aa, aba, ba\} \cup \{aab, abab, bab\} \cup \{ab, abb, bb\}$

$= \{ aa, ab, ba, bb ,aab, aba, abb, bab, abab\}$

Műveletek nyelveken

Nyelv hatványa:

Legyen L egy tetszőleges nyelv.

Nemnegatív egész hatványai:

$L^0 := \{\varepsilon\}$

$L^1 := L$

$L^n := L^{n-1}L$, ahol $n \geq 1$.

Műveletek nyelveken

Nyelv lezártja (iteráltja):

Legyen L egy tetszőleges nyelv.

$L^* := L^0 \cup L^1 \cup L^2 \cup \ldots$ az L nyelv lezártja.

Másképpen:

$L^* := \bigcup_{i \geq 0} L^i$ valamint $L^+ = \bigcup_{i \geq 1} L^i$

Pédák

Legyen $L = \{a, ab\}$.

$L^* = \{\varepsilon\} \cup \{a, ab\} \cup \{aa, aab, aba, abab\} \cup \ldots$

$(ab)^3 \in L^*$, de $ab^3 \notin L^*$. // $(ab)^3 = ababab$; $ab^3 = abbb$

$\{ a^n b \mid n>0 \} \subseteq L^*$, de $a^0 b \notin L^*$. // $a^0 b = \varepsilon b = b$

$\varepsilon \in L^*$, de ebben a konkrét esetben $\varepsilon \notin L^+$.

Pédák

Legyen L = {ε,a,ab} .

L* = {ε} ∪ {ε,a,ab} ∪ {ε,a,aa,ab,aab,aba,abab} ∪ …

$(ab)^3 \in L^*$, de $ab^3 \notin L^*$. // $(ab)^3 = ababab$; $ab^3 = abbb$

$\{ a^n b \mid n>0 \} \subseteq L^*$, de $a^0 b \notin L^*$. // $a^0 b = \varepsilon b = b$

$\varepsilon \in L^*$, de ebben a konkrét esetben $\varepsilon \in L^+$ -nak is.

Ebben az esetben $L^* \setminus \{\varepsilon\} \neq L^+$.

Műveletek nyelveken

Az alábbi három nyelvi műveletet **reguláris** műveletnek nevezzük:

- unió,
- konkatenáció,
- lezárás.

Nyelvek megadási módjai

- logikai formulával
- strukturális rekurzióval
- algoritmussal
- matematikai gépekkel
- produkciós rendszerekkel (szabályokkal)

Programozási nyelvek szintaxisa

Gyakran Backus-Naur formában (BNF) adják meg.

Példa:

<kifejezés> ::= <tag> | <tag> + <kifejezés>

<tag> :: = <faktor> | <faktor> * <tag>

<faktor> ::= i | (<kifejezés>)

Példák kifejezésekre:

i+i*i, (i+i)*i, i*i*i*i, ((i)), i

V={+,*,(,),i} felett értelmezett szavak

Emlékeztető:

V - ábécé, jelek nem üres véges halmaza;

V* - az adott jelkészlet felett értelmezett összes szó;

$L \subseteq V^*$ - formális nyelv, szavak halmaza.

Nyelv megadása szabályrendszerrel

Definíció: Grammatikának (nyelvtannak) a következő négyest nevezzük:

G=(N,T,P,S)

- **N** a nemterminális ábácé,
- **T** a terminálisok ábécéje,
- **P** az átírási szabályok véges halmaza,
- **S** a kezdőszimbólum.

Grammatika: G=(N,T,P,S)

- N és T diszjunkt halmazok, azaz $N \cap T = \emptyset$.
- S $\in$ N, kezdőszimbólum.
- A szabályok $p \rightarrow q$ alakúak, ahol $p \in (N \cup T)^* N (N \cup T)^*$, $q \in (N \cup T)^*$ és p jelöli a szabály baloldalát, q a jobboldalát, $\rightarrow$ a két oldalt elválasztó jel.
- A szabályok baloldala kötelezően tartalmaz legalább egy nemterminális szimbólumot.
- $(N \cup T)^*$ elemeit *mondatformá*knak nevezzük.

Grammatika által generált nyelv

Minden olyan szó, amely közvetetten levezethető a kezdőszimbólumból.

$L(G) := \{ u \in T^* \mid S \overset{*}{\underset{G}{\Rightarrow}} u \}$

Generatív grammatika (nyelvtan)

Példa:

G = ({S}, {a,b}, {S → aSb, S → ab}, S) egy ***grammatika***.

Ez a grammatika az L={ $a^n b^n$ | n ≥ 1 } ***nyelv***et definiálja, azaz L(G)=L.

Levezetés:

$S \underset{G}{\Rightarrow} aSb \underset{G}{\Rightarrow} aaSbb \underset{G}{\Rightarrow} aaaSbbb \underset{G}{\Rightarrow} aaaabbbb$

$S \underset{G}{\Rightarrow}^* a^4b^4$

Közvetlen levezetés

Legyen $G = (N, T, P, S)$ egy adott grammatika.

Legyen $u, v \in (N \cup T)^*$.

Azt mondjuk, hogy a **v** mondatforma ***közvetlenül*** levezethető az **u** mondatformából, ha létezik $u_1 , u_2 \in (N \cup T)^*$ és $x \rightarrow y \in P$ úgy, hogy $u = u_1xu_2$ és $v = u_1yu_2$.

Jelölése: $u \underset{G}{\Rightarrow} v$

Példa

u = abBcaaAcb

v = abcaBAaAcb

Bca $\rightarrow$ caBA $\in$ P

Az u modatformából közvetlenül levezethető a v mondatforma a megadott szabály segítségével.

ab**Bca**aAcb $\underset{G}{\Rightarrow}$ ab**caBA**aAcb, ahol u_1=ab és u_2=aAcb

Közvetett levezetés

Legyen G = (N, T, P, S) egy adott grammatika.

Legyen u, v ∈ (N ∪ T)*.

Azt mondjuk, hogy a v mondatforma ***közvetetten*** levezethető az u mondatformából, ha létezik olyan k ≥ 0 szám és x_0 ,…, x_k ∈ (N ∪ T)* , hogy

u = x_0 és v = x_k és ∀ i ∈ [0,k-1]: $x_i \underset{G}{\Rightarrow} x_{i+1}$.

Jelölése: $u \underset{G}{\Rightarrow}^* v$

Grammatika által generált nyelv

Minden olyan szó, amely közvetetten levezethető a kezdőszimbólumból.

$L(G) := \{ u \in T^* \mid S \overset{*}{\underset{G}{\Rightarrow}} u \}$

Példa:

G = ({S,A,B}, {a,b}, P, S) egy grammatika.

P: $S \rightarrow ASB$

$S \rightarrow AB$

$AB \rightarrow BA$ //csere szabály

$A \rightarrow a$

$B \rightarrow b$

$L(G)=\{ u \in \{a,b\}^* \mid \ell_a(u)=\ell_b(u) \geq 1 \}$ nyelvet definiálja.

(Ugyanannyi ‚a' és ‚b' betű van a szavakban.)

Levezetés (példa egy szó levezetésére):

$S \underset{G}{\Rightarrow}^* A^nB^n \underset{G}{\Rightarrow} A^{n-1}BAB^{n-1} \underset{G}{\Rightarrow}^* BA^{n-1}AB^{n-1} \underset{G}{\Rightarrow}^* ba^nb^{n-1}$

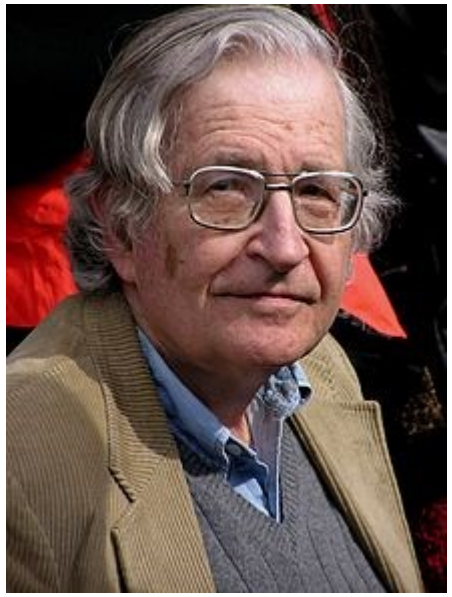
Ekvivalencia

A G_1 es G_2 nyelvtanok ***ekvivalensek***, ha

$L(G_1) = L(G_2)$, azaz ugyanazt a nyelvet generálják.

Gyengén ekvivalensek, ha $L(G_1)\setminus \{\varepsilon\} = L(G_2)\setminus\{\varepsilon\}$.

Noam Chomsky (született: 1928)



Noam Chomsky amerikai nyelvész, a Massachusetts Institute of Technology professzora, a generatív nyelvtan elméletének megalkotója, filozófus, politikai aktivista, előadó és lektor. Kidolgozója a róla elnevezett Chomsky-hierarchiának. (Wikipédia)

Köszönöm a figyelmet!